

VLM 과제

2026.5.8.

다음은 강의시간에 제시한 small VLM 구조 이해에 관한 코딩 문제입니다.

(1) image 영역의 시작과 끝을 구분하기 위해 [IMG_START], [IMG_END] 두 개 token 넣기

[목표]

기존 : image_tokens + text_tokens

변경 : [IMG_START] + image_tokens + [IMG_END] + text_tokens

[과제 제출]

- decoder input shape 출력
- sequence length 증가분 출력
- 첫번째/마지막 image token 출력
- token별 위치 출력

(예시)

0: IMG_START

1~10: image

10: IMG_END

10~20: text

(2) text 없이 image token만 decoder에 넣기

[목표]

기존 : image_tokens + text_tokens

변경 : image_tokens only

[과제 제출]

- decoder input shape 출력
- image token 개수 출력
- text token 개수 출력
- sequence length 출력
- token별 위치 출력

(3) 강의시간에 제시한 small VLM 코드에서:

Vision Encoder가 만든 image feature를 Projector를 거쳐 Decoder에 넣기 전에 learnable special token([IMG_SUM]) 하나를 추가해 보세요.

즉, [IMG_SUM] + projected_image_tokens + text_tokens 형태로 decoder input 구성

[과제 제출]

- decoder input shape 출력
- 첫 번째 token 값 출력
- parameter 개수 증가에 관한 정보 출력
- IMG_SUM 역할 설명
- token별 위치 출력

(4) Multi-view Image Embedding Concatenation

[목표]

여러 각도에서 찍은 이미지를

그냥 "이미지 토큰을 이어붙여서" 하나의 입력으로 만드는 것

(진짜 "fusion learning" 아님, "token concatenation 실습")

(4.1) 동일 이미지에 대해서 camera view가 다른 2-3장 이미지를 embedding concat하세요.

[과제 제출]

- 이미지 개수 출력
- embedding shape 출력
- 이미지 개수에 따른 sequence 길이 출력
- multi-image 입력 caption 1개 출력

(4.2) front view와 side view image 2개를 모델에 입력으로 주고,
모델이 여러 view를 '하나의scene'으로 이해하는지 테스트해 보세요.

prompt:

"These images show the same object from different views. Describe it."

[과제 제출]

결과 caption

2~3줄 설명

(4.3) multi-image concat 효과를 확인하는 비교 실험을 진행하세요.

(1) image only

(2) image1 + image2 concatenated

[과제 제출]

caption 비교

어떤 정보가 추가됐는지 설명

다음은 강의시간에 제시한 small VLM에서 사용한 HuggingFace Transformer에 관한 코딩 문제입니다.

(1) Attention Map 출력해서 “어디를 보는지 확인하기”

[목표]

HuggingFace encoder의 self-attention을 추출하고
특정 head의 attention을 heatmap으로 시각화하여 token간 관계를 확인
즉, 마지막 layer의 attention matrix에서 첫 번째 head를 선택하여
token 간 attention 관계를 heatmap으로 시각화

[사용 조건 (중요)]

다음 조건을 반드시 사용하세요:

encoder-only 모델 사용 (예: ViT)

output_attentions=True 설정

return_dict=True 유지 (default)

[과제 제출]

- encoder의 마지막 Transformer block에서 계산된 self-attention shape 출력
- 마지막 layer의 첫 번째 attention head에서 앞 5개 token에 해당하는 attention matrix 일부를 출력하세요.
- 마지막 layer의 첫 번째 self-attention을 heatmap으로 시각화하여 디스플레이하세요.
(token 간 attention 관계를 색으로 표현)

(예시)

	patch1	patch2	patch3	patch4
patch1	0.2	0.3	0.1	0.4
patch2	0.1	0.5	0.2	0.2
patch3	0.3	0.2	0.4	0.1
patch4	0.2	0.1	0.3	0.4

.....

(2) 특정 layer output 비교하기

[목표]

encoder의 “중간 layer vs 마지막 layer” 비교

[과제 제출]

- layer별 shape 출력
- 각 layer에서 첫 번째 sample의 앞 5개 token, 앞 5개 hidden dimension 값 출력

(3) 특정 layer freeze / unfreeze 실험

[목표] encoder 일부만 학습 가능한 상태로 만들기

[구현 예시 코드]

```
for name, param in model.named_parameters():  
    if "encoder.layer.0" in name:  
        param.requires_grad = False
```

[과제 제출]

- trainable parameter 수 출력

(4) token embedding noise 넣기

[목표] 입력 embedding perturbation

[과제 제출]

- output 비교 출력

다음은 강의시간에 제시한 small VLM 기반 Image Captioning task 관련 '입력 형식 + prompt 변환 + 출력 관찰'에 관한 문제입니다.

(1) Prompt 바꾸기 실험

[목표]

같은 이미지에 대해 prompt에 따라 caption이 어떻게 달라지는지 비교

[과제 내용]

다음 3가지 prompt를 사용하여 동일 이미지에 대해 결과 비교:

- (1) "Describe this image."
- (2) "What is happening in this image?"
- (3) "Explain this image in one sentence."

[과제 제출]

각 prompt별 생성 결과 1개씩 출력

결과 비교 2~3줄 작성

(2) zero-shot 이미지 2~3개 비교

[목표]

입력 이미지가 바뀌면 caption이 어떻게 달라지는지 확인

[과제 내용]

다음 중 2~3개 이미지 사용:

- 자유의 여신상
- 에펠탑
- 고양이 / 강아지 이미지

각 이미지에 동일 prompt 사용:

"Describe this image in detail."

[과제 제출]

이미지별 caption 출력

이미지-결과 pair 비교

(3) Prompt 길이 변화 실험

[목표]

prompt 길이에 따른 output 변화 확인

[과제 내용]

같은 이미지에 대해 prompt 2개 비교:

- (1) "Describe."
- (2) "Please describe this image carefully and explain what is happening in detail."

[과제 제출]

두 결과 비교 출력

어떤 prompt가 더 상세한지 설명

(4) 질문형 vs 명령형 비교

[목표]

prompt 형태가 결과에 미치는 영향 확인

[과제 내용]

(1) "What is in this image?"

(2) "Describe this image."

[과제 제출]

두 결과 출력

차이 2~3줄 설명

(5) caption 길이 제한 실험

[목표]

모델 생성 길이 제어 이해

[과제 내용]

token 개수의 최대값을 30 또는 80으로 설정하고 결과 비교

[과제 제출]

두 결과 비교

길이에 따른 정보 변화 설명

(6) hallucination 관찰

[목표]

모델이 이미지에 없는 정보를 생성하는 경우 확인

[과제 내용]

복잡한 이미지 1개 사용

prompt:

"Describe everything in the image accurately."

[과제 제출]

출력 결과

"사실과 다른 내용이 있는지" 체크